


535109 生成式人工智能 · 2026 SPRING

HW3: Hallucination Type Classification in Peer Reviews

助教: 林子凌 (Tzu-Ling Lin)

截止日期: 2026/05/05 23:59 (完成 E3、Kaggle 繳交)



任務類型

5 類幻覺分類

Macro F1 評估

指定模型


Qwen2.5-3B-Instruct-bnb-4bit

QLoRA 微調

資料規模

5,695 訓練筆數

類別不平衡 15:1



任務背景與核心目標

隨著 LLM 被廣泛用於學術評審輔助，模型生成的評審內容可能產生各種「幻覺 (Hallucination)」。本次作業以 **Kaggle 分類競賽** 形式進行，給定論文評審句子與相關段落，訓練微調 LLM 判斷幻覺類型 (5 類多分類)。



PEFT 微調

以 **QLoRA** 進行 Parameter-Efficient Fine-Tuning



Prompt 工程

為分類任務設計 Instruction Prompt 模板



類別不平衡

處理嚴重類別不平衡問題 (15:1)



非結構化資料

使用 parsing 工具將 PDF 轉為結構化文字

課程學習進程

HW3 是本課程三次作業的集大成，綜合運用前兩次的LLM 微調與 RAG 流程，並引入更複雜的資料工程與跨文件比對推理挑戰。

比較維度	HW1	HW2	HW3(本次)
核心技術	LoRA Fine-tuning	RAG Pipeline	QLoRA + Data Engineering
使用模型	Llama-3.2-1B	Llama-3.2-3B(僅推論)	Qwen2.5-3B-Instruct-bnb-4bit
輸入形式	單一問題 + 4 選項	問題 + 整篇論文(Retrieval)	評審句子 + 論文段落 (模型自行比對)
標籤結構	4 選 1	開放式生成	5 類, Max/Min = 15:1
評估指標	Accuracy	Answer Correctness + ROUGE-L	Macro F1(對不平衡敏感)

 HW3 的評估從 Accuracy 換成 **Macro F1**:即使多數類預測完美，少數類F1 極低仍會大幅拉低總分——每個類別的表現同等重要。

HW3 的三個核心新挑

戰

相較於 HW1/HW2, 本次作業引入三項全新設計挑戰, 每一項都需要學生主動規劃解決策略。

1

Evidence-grounded 分類 (跨文件比對推理)

模型須同時閱讀**評審句子**與**論文段落**, 主動找出兩者差異以判斷幻覺類型。這個比對邏輯必須透過精心設計的 System Prompt 明確引導, 是本次作業的核心推理能力。

2

類別不平衡資料取樣訓練 (Max/Min = 15:1)

最多類 (Attribution Failure) 是最少類 (Temporal) 的 **15 倍**。在 Macro F1 機制下, 少數類 F1 極低仍會大幅拉低總分。學生必須主動設計過採樣或加權損失策略。

3

自行解析 PDF 提取文本 (非結構化資料前處理)

系統不直接提供論文文字檔, 學生需自行使用開源套件 Parse PDF, 準確提取 Paper content 作為比對 Evidence。額外考驗資料抽取、排版解析與雜訊過濾的工程能力。

指定模型與微調規範

本次統一使用 **unsloth/Qwen2.5-3B-Instruct-bnb-4bit**, 讓同學將重心放在微調策略本身。

✓ 允許實作

- 必須使用 PEFT (QLoRA)
- 支援套件: transformers, peft, trl, bitsandbytes, accelerate, unsloth

✗ 嚴格禁止

- 使用其他 LLM (Llama-3、GPT-4 等)
- Full Fine-tuning (禁止解凍全部參數)

硬體建議

單張 T4 (16GB): 推論 3-4 GB, 訓練 3-6 GB VRAM

雙張 T4 (32GB): Kaggle 預設, 具高彈性



強烈建議搭配

Unsloth
訓練提速 **2-3x**, 大幅縮短實驗週期

節省 **30%** 記憶體, 使 QLoRA 更穩健

讓 3B 模型在低 VRAM 環境高效訓練



unsloth

資料集結構與欄位 說明

明

完整資料集包含訓練、驗證、測試三個劃分及論文 PDF 原始檔案。

train.csv(5,695 筆)

包含完整 text、paper_id 與標籤，是唯一合法訓練來源。請根據 paper_id 對應 paper_evidence/{paper_id}.pdf。

dev.csv(1,777 筆)

驗證集，格式與訓練集相同，提供 label 欄位供本地評估。**不可混入訓練流程**，僅用於驗證效能。

test.csv(1,778 筆)

推論時**僅可使用** text(評審句子)與從 PDF 自行 parsing 的論文 Evidence。label 欄位不存在。

paper_evidence/{id}.pdf

各論文 PDF 原始檔。需自行 parsing 成結構化純文字。全文平均約 155 KB(~40K tokens)，**務必截斷至合理長度**。

❏ 推論時核心輸入為 **text**(含幻覺的評審句子)與對應 paper_id 的論文 Evidence。label 欄位僅在 Train/Dev 存在。

資料集結構與欄位 說


classes.json

包含類別、類別描述、對應id, 用於輔助訓練。推論結果需要讓LLM輸出類別再mapping至id, 不可用logit分類

```
{
  "concept": "Attribution Failure",
  "concept_desc": "A claim lacks proper attribution, either crediting the wrong source or presenting information as fact without citation.",
  "id": 0
},
{
  "concept": "Entity",
  "concept_desc": "A claim includes swapped, incorrectly specified, or inserted noun phrases (e.g. one named entity used in a context where another word is expected).",
  "id": 1
},
{
  "concept": "Number",
  "concept_desc": "A claim has a different number than the original context (e.g. 20% vs. 0.7%). Any number, including year, dimensions, ages, etc.",
  "id": 2
},
{
  "concept": "Overgeneralization",
  "concept_desc": "A claim is based on accurate contextual information but is too broad or too general to be supported by the context.",
  "id": 3
},
{
  "concept": "Temporal",
  "concept_desc": "A claim does not accurately incorporate tense, modality (e.g. might vs. will), or time reference in relation to the context.",
  "id": 4
}
```

幻覺類型與資料分布

理解各類別分布是設計平衡策略的第一步。訓練集共 **5,695 筆** (942 篇論文), **Max/Min 比例 = 15:1** (嚴重不平衡)。



Temporal 類別僅 130 筆, 是 Attribution Failure (1,910 筆) 的 **1/15**。
少數類若 F1 極低, Macro F1 將大幅下滑。

進階探索方向參考

以下方向不列入評分，但對最終 Macro F1 的提升有顯著影響，鼓勵積極嘗試。

01 Context Length 處理

paper_evidence 全文平均 ~40K tokens，建議設定合理 max_length，並嘗試**語意相關段落抽取**（類似 Retrieval 思路），只餵入最相關段落降低噪音。

02 Prompt Template 設計

單純拼接 text 與 paper_evidence 效果通常不佳。設計明確 **System Prompt** 指引模型比對差異，並嘗試 **Chain-of-Thought** 引導，可提升推理準確性。

03 QLoRA 超參數調整

調整 r 與 lora_alpha，優化 learning_rate 與 batch_size。嘗試在不同層(query, key, value, FFN)掛載 Adapter 以平衡容量與收斂速度。

04 類別不平衡處理策略

使用不同採樣策略搭配資料增強來增加少數類樣本，同時在 Loss 計算時放大對少數類預測錯誤的懲罰。兩者互補能有效校正模型偏誤，是提升 Macro F1 的關鍵手段。

評分標準與提交規範

Kaggle 評分機制(100%)

條件	得分
Macro F1 > 0.60 (超過 Weak Baseline)	70%
Macro F1 > 0.65 (超過 Strong Baseline)	80%
排名 50%~75%	+5%
排名 25%~50%	+10%
排名前 25%	+20%

 最終成績以 **Private Test(70%)** 計算, 請避免過度擬合 Public 排名 (30% Test)。每日提交上限 **3 次**, 請合理分配。

重要注意事項

- 嚴禁將 Dev/Test Set 以任何方式加入訓練流程
- 禁止使用其他模型標註 Test Set 並上傳
- 必須使用 PEFT (QLoRA), 嚴禁 Full Fine-tuning
- 必須使用 unsloth/Qwen2.5-3B-Instruct-bnb-4bit, 不可替換
- 推論時只能使用 text 與自行 parsing 的 paper_evidence
- 不可拿 logit 分類, 請讓 LLM 預測類別
- 不要將資料集上傳至 E3, 僅上傳程式碼、adapter checkpoint 與預測結果
- Kaggle Team Name 請包含學號, 以便 TA 核對成績
- 禁止抄襲程式碼

繳交格式、時程與免費 GPU 環境

繳交時程



壓縮包結構

```
hw3_{student_id}/
├─ train.py          ← 微調程式碼
├─ inference.py      ← 推論程式碼
├─ adapter_checkpoint/... ← 訓練好的 LoRA adapter
├─ hw3_{student_id}.csv ← 最終 Kaggle 預測結果
├─ requirements.txt  ← 環境套件清單
└─ README.md         ← 環境、資料放置位置說明與執行指令
```

免費 GPU 環境推薦

平台	GPU	限制	備註
Kaggle	P100 / T4 × 2	30 小時/週, 單次最長 12 小時	強烈推薦, 直接掛載 Dataset 最方便
Google Colab	T4	連線時間較短, 免費版易斷線	建議搭配 Colab Pro
Lightning AI	T4	免費 22 小時/月	支援 VS Code 介面

✅ **標準解法提示:** 搭配 `bitsandbytes` (4-bit 量化) 與 `peft` (QLoRA) 是將 Qwen2.5-3B-Instruct 塞進 15 GB VRAM 進行微調的標準方案。使用 `unsloth` 可進一步加速 2-3 倍, 強烈建議採用。

推論重現指令

務必確保以下指令可正確重現結果:

```
python inference.py
```

祝大家作業順利！

如有任何問題

請透過以下方式尋求協助：

- 在 [E3 寄信給 TA](#) 或在 [討論區發問](#)
- 於 **TA Hours** 前來詢問（請先透過 E3 來信約時間）

TA: 林子凌

 **Final Deadline: 2026/05/05 (Tue.) 23:59**

Kaggle 競賽連結：

<https://www.kaggle.com/t/e481a2799bb4ff1117d505d5fee612c6>